生成AIにおけるハルシネーションの原理とその対策：arXiv論文に基づく包括的分析

I. 序論 (Introduction)

A. 生成AIにおけるハルシネーションの定義と重要性 (Definition and Significance of Hallucination in Generative AI)

近年、目覚ましい発展を遂げている生成AI（Generative Artificial Intelligence）、特に大規模言語モデル（LLM）は、人間と自然に対話する能力や、多様なテキストコンテンツを生成する能力により、多くの分野で革新をもたらす可能性を秘めています。しかし、これらのモデルは、一見もっともらしく、流暢であるものの、実際には事実と異なる、あるいは提供された文脈にそぐわない情報を生成するという特有の課題を抱えています。この現象は一般に「ハルシネーション（幻覚）」と呼ばれています。

ハルシネーションは、生成AIが生成する出力に、不正確な事実、捏造された情報、または誤解を招く情報が含まれる場合に発生し、特に医療、法律、金融、科学研究といった、情報の正確性と信頼性が極めて重要となる分野において、重大なリスクをもたらします [1]。例えば、医療診断支援システムが誤った医学情報を生成したり、法律相談AIが不正確な法的助言を行ったりする可能性は、深刻な結果を招きかねません。この問題は、LLMの信頼性と実用性を著しく損なう主要な障害の一つとして認識されています [3]。

このハルシネーションという現象は、単なるランダムな誤りとは異なり、モデルが訓練データや入力されたコンテキストには存在しない情報を、あたかも真実であるかのように「創造」してしまうという特徴的なエラーです [10]。生成された内容が文法的に正しく、論理的にも一貫しているように見える場合があるため、人間がその誤りに気づきにくいという側面も持っています [4]。このような特性は、誤情報に基づく意思決定の誤りを引き起こすだけでなく、ユーザーのAIシステムに対する信頼を根本から揺るがし、その広範な受容と発展を妨げる可能性があります [11]。複数の研究論文が一貫してハルシネーションを「重大なリスク」[1]、「決定的な障壁」[7]、あるいは「主要な障害」[9]と指摘している事実は、この問題の普遍性と深刻さを物語っています。この問題の解決は、責任あるAIの普及に向けた前提条件と言えるでしょう。

さらに、ハルシネーションは「独特なエラー」[3]や「誤情報の一形態」[10]として概念化されており、その「もっともらしいが誤っている」という性質が特に問題視されています。このもっともらしさが、偶発的なユーザーによる検出を困難にし、単純な文法誤りや意味不明な出力よりも大きな誤解を生むリスクを孕んでいます。このため、ハルシネーションには、一般的なエラー修正を超えた専門的な検出および緩和戦略が必要とされます。

B. 本報告書の目的と構成 (Aim and Structure of this Report)

本報告書は、学術論文公開サイトarXivで公開されている最新の研究論文に基づき、生成AI、特にLLMにおけるハルシネーションの発生原理を多角的に分析し、現在提案されている主要

な対策法を体系的に整理・解説することを目的とします。

報告書の構成は以下の通りです。まず第II章で、ハルシネーションの基本的な定義と、研究コミュニティで議論されている様々な分類法について詳述します。第III章では、ハルシネーションが発生する原因を、訓練データの問題、モデルアーキテクチャや学習プロセスの特性、内部知識と外部知識の間の競合、そしてLLMが持つ本質的な限界といった複数の観点から深く掘り下げます。続く第IV章では、これらの原因に対処するために開発されている多岐にわたる対策アプローチ、すなわち検出技術、データ中心のアプローチ、モデル中心のアプローチ、検索拡張生成（RAG）技術、そして自己修正メカニズムについて、具体的なフレームワークや手法を交えながら紹介します。第V章では、ハルシネーションの程度や対策の効果を評価するための主要な指標とベンチマークについて概観します。最後に第VI章で、本報告書で得られた主要な知見を要約し、残された課題と今後の研究の方向性について展望します。

II. ハルシネーションの理解 (Understanding Hallucinations)

A. ハルシネーションの定義 (Defining Hallucination)

大規模言語モデル（LLM）におけるハルシネーションは、一般的に「モデルが生成する出力が、もっともらしく見えるものの、事実や提供された文脈に忠実でないインスタンス」として定義されます [13]。この定義は、Filippova (2020) の研究に遡ることができます。より広義には、モデルが訓練データや推論時に入力としてアクセスした知識と矛盾する内容を生成する場合もハルシネーションと関連付けられます [11]。Jiら (2023) の研究では、このアクセス可能な知識との一貫性が焦点とされています。

具体的には、ハルシネーションは以下のような形で現れます：

1. 生成されたテキストが、検証可能な既知の事実と矛盾する場合 [1]。
2. 入力されたコンテキスト（例えば、ユーザーのプロンプトや参照文書）に存在しない、あるいはサポートされていない内容をモデルが導入する場合 [1]。
3. モデル自身が生成したテキストの内部で矛盾した情報を提示する場合 [1]。

これらの定義は、ハルシネーションが単なる不正確さではなく、モデルが情報を「捏造」したり、文脈を無視したり、あるいは自己矛盾に陥ったりする、より複雑な現象であることを示唆しています [1]。

B. ハルシネーションの分類 (Taxonomy of Hallucinations)

ハルシネーションの現象は多様であり、その特性に応じていくつかのカテゴリに分類されています。これらの分類を理解することは、原因の特定や適切な対策法の選択において極めて重要です。

1. 内在的ハルシネーション **vs.** 外在的ハルシネーション **(Intrinsic vs. Extrinsic**

Hallucination)

この分類は、ハルシネーションが参照する情報のソースに基づいています[1]。

- 内在的ハルシネーション **(Intrinsic Hallucination):** 生成されたテキストが、提供されたソースコンテキスト（入力クエリや参照文書など）と矛盾する場合、またはソースコンテキストによって支持されない情報を生成する場合を指します[11]。例えば、ある文書の要約を生成する際に、元の文書には書かれていない情報を要約に含めてしまったり、元の文書の内容と矛盾する記述をしてしまったりするケースがこれに該当します[1]。このタイプのハルシネーションは、モデルが入力コンテキストを正しく理解または追従できなかった場合に発生し、その検証はソースコンテキストとの比較によって比較的容易に行うことができます[11]。
- 外在的ハルシネーション **(Extrinsic Hallucination):** 生成されたテキストが、ソースコンテキストによっては検証できず、外部の一般知識や現実世界の事実と照らし合わせて初めて矛盾が明らかになる場合を指します[1]。モデルが訓練データには存在するかもしれないが、現在の入力コンテキストでは支持も反論もできない新しい情報を生成する場合や、知識のギャップを埋めようとして不正確な情報を「創造」する場合にしばしば発生します[11]。例えば、「フランスの首都はどこですか？」という質問に対して「ベルリンです」と答えるような場合がこれにあたります。

この内在的と外在的の区別は、検証可能性という点で重要な意味を持ちます。内在的ハルシネーションはソースコンテキストとの照合で検出できる可能性があるのに対し、外在的ハルシネーションの検出には、広範な外部知識ベースとの照合が必要となり、より複雑な事実確認メカニズムが求められます。この違いは、後述する検出技術や対策戦略の設計に直接的な影響を与えます。

2. 事実的ハルシネーション **vs.** 意味的ハルシネーション **(Factual vs. Semantic Hallucination)**

この分類は、ハルシネーションが主に事実の誤りに関するものか、意味論的な不整合に関するものかという点に着目しています[1]。

- 事実的ハルシネーション **(Factual Hallucination):** 生成された記述が、検証可能な現実世界の事実と矛盾する場合を指します[1]。例えば、歴史的な出来事の日付を誤って述べたり、科学的な定数を間違えたりするケースです。「光の速度は毎秒3×105 kmである」と述べるべきところを、異なる数値を提示するなどが典型例です。このタイプのハルシネーションは、特に医療AIや法律分析など、事実の正確性が絶対的に求められる応用分野で深刻な問題となります[1]。
- 意味的ハルシネーション **(Semantic Hallucination):** 生成されたテキストが文法的には正しく、一見するともっともらしいものの、論理的な一貫性に欠けていたり、与えられたプロンプトや文脈との関連性が希薄であったりする場合を指します[1]。対話システムにおいて、ユーザーの質問に対して流暢ではあるものの、無関係であったり、無意味であったり

する応答を返す形で現れることがあります。例えば、「日本の首都は？」という問いに対して、「東京の食文化は多様で素晴らしいです」といった、話題がずれた応答をする場合などです[1]。

3.「腐食性」ハルシネーション (Corrosive Hallucination)

科学研究のような特定の応用分野では、ハルシネーションが推論プロセス全体を蝕む可能性があります。Rathkopf (arXiv:2504.08526) は、このような科学的推論を脅かすハルシネーションの特に問題となるサブクラスとして、「腐食性ハルシネーション（Corrosive Hallucination）」という概念を提案しています[3]。これは、単に不正確であるだけでなく、実質的に誤解を招き、かつ体系的な予測や検出が困難な誤表現を指します[3]。

腐食性ハルシネーションの重要な点は、その定義がモデルの内部的な特性のみ（例えば、出力が訓練データと一致しないなど）によってなされるのではなく、モデルが対象とする経験的なターゲットシステム（例えば、タンパク質の構造や気候変動のパターン）との関連において評価されるべきであるという主張にあります[3]。この視点は、ハルシネーションの影響をより実世界の問題解決の文脈で捉えようとするものであり、単なる技術的な誤りを超えて、その誤りが特定の知識領域や応用タスクにどのような悪影響を及ぼすかを重視します。このような影響志向の分類は、特に科学や医療などのクリティカルなドメインでLLMを利用する際に、どのタイプのハルシネーションが最も警戒すべきかを判断する上で有益です。ハルシネーションの定義や分類法が進化し続けていることは、この問題の複雑さと、より的を絞った研究の必要性を示唆しています。

以下の表1に、本節で述べたハルシネーションの主要な分類をまとめます。

表1: ハルシネーションの分類 (Taxonomy of Hallucination Types)

種類 (Type)	定義 (Definition)	例 (Example)	主要参考文献 (Key References)
内在的ハルシネーション (Intrinsic)	生成テキストが提供されたソースコンテキストと矛盾する、またはサポートされない情報を生成する。	要約文が元文書と異なる生年月日を記載する。	[1]
外在的ハルシネーション (Extrinsic)	生成テキストがソースコンテキストでは検証できず、外部の一般知識や事実と矛盾する。	「フランスの首都はベルリン」と回答する。	[1]

事実的ハルシネーション (Factual)	生成された記述が、検証可能な現実世界の事実と矛盾する。	光の速度を誤った値で述べる。	[1]
意味的ハルシネーション (Semantic)	生成テキストが文法的に正しく一見もっともらしいが、論理的一貫性やプロンプトとの関連性に欠ける。	「日本の首都は？」に対し「東京の食文化は素晴らしい」と無関係な応答をする。	[1]
腐食性ハルシネーション (Corrosive)	実質的に誤解を招き、体系的な予測が困難で、科学的推論のような経験的ターゲットシステムに対する信頼性を脅かす誤表現。	科学論文の自動生成において、もっともらしいが誤った実験結果や結論を生成し、研究コミュニティを誤導する可能性があるケース。	[3]

III. ハルシネーション発生の原理と原因 (Principles and Causes of Hallucination)

ハルシネーションは単一の原因によって引き起こされるのではなく、データの特性、モデルのアーキテクチャや学習プロセス、知識の表現と利用方法、さらにはLLMの根本的な能力限界など、複数の要因が複雑に絡み合って発生します。これらの原因を理解することは、効果的な対策を講じる上で不可欠です。

A. データ起因の原因 (Data-Driven Causes)

LLMの性能は、その訓練に使用されるデータの質と量に大きく依存します。データに起因する問題は、ハルシネーションの主要な源泉の一つです。

1. 訓練データの限界とバイアス (Training Data Limitations and Biases)

LLMは膨大なテキストデータからパターンを学習しますが、そのデータが完全無欠であることは稀です。訓練データセットに存在する以下のような問題が、ハルシネーションを引き起こす可能性があります。

- 知識の欠落（データヴォイド）: 訓練データがある特定のトピックや情報ドメインを十分にカバーしていない場合、その領域に関する質問に対してモデルは不正確な情報を生成しやすくなります。これは「データヴォイド（data voids）」として知られています [10]。
- 社会的バイアス: 訓練データが特定の社会的・文化的なバイアス（例えば、ジェンダーバイアスや人種的偏見など）を含んでいる場合、モデルもこれらのバイアスを学習し、偏った、あるいは不公平な出力を生成する可能性があります [10]。これは、Crawford (2021)などが指摘する問題です。

- データの品質問題: 訓練データにノイズが多い、誤った情報が含まれている、あるいは低品質である場合、モデルはこれらの問題点を学習してしまい、結果として不正確な情報を生成しやすくなります [1]。
- ソースと参照の不一致: 特に要約タスクなどのためのデータセットにおいて、参照されるべきソーステキストと、それに対応する「正解」の参照テキスト（例：人間が作成した要約）との間に不一致が存在する場合があります。例えば、参照要約がソーステキストではサポートされていない追加の主張や情報を含んでいる場合（source-reference divergence）、モデルはこのパターンを学習し、ハルシネーションを生成する傾向を強める可能性があります [1]。
- 馴染みのない知識: ファインチューニングや命令チューニングの段階で、モデルが事前学習段階で十分に学習していない、あるいは馴染みのない新しい知識を含むデータを使用すると、モデルがその知識を正確に消化できず、過度に自信過剰な状態で誤った情報を生成し、ハルシネーションを助長する可能性があります [14]。Kangら (2024) やLinら (2024b) の研究がこの点に言及しています。

これらのデータの問題は、モデルが世界の知識を不完全または歪んだ形で学習することにつながり、結果としてハルシネーションという形で現れます。

2. 知識境界と不確実性 **(Knowledge Boundaries & Uncertainty)**

AIシステム、特にLLMは、自身の知識の限界を正確に認識する能力がまだ十分ではありません。

- 未解決の科学や不確実なトピックへの対応: LLMは、科学的に未解決の問題や、明確で信頼できる根拠（グラウンドトゥルース）が確立されていないトピックについて質問された場合でも、何らかの回答を生成しようとする傾向があります [10]。このような状況では、モデルは既存の知識から類推したり、もっともらしいパターンを生成したりしますが、それが結果的にハルシネーションとなることがあります。Augensteinら (2024) の研究は、AIがこのような不確実な情報をどのように扱うかという問題に取り組んでいます。
- 知識の限界の不認識: モデルが自身の知識が及ぶ範囲を正確に把握できず、知らないことに対しても自信を持って答えてしまうことが、特に外在的ハルシネーションの一因となります [11]。
- 比喩や単純化による誤解: たとえ科学的なコンセンサスが存在するトピックであっても、モデルが理解を助けるために比喩や過度な単純化を用いた結果、かえってユーザーに誤解を与え、ハルシネーションと見なされる情報を生成することがあります [10]。

モデルが「知らない」ということを認識し、それを適切にユーザーに伝える能力の欠如は、ハルシネーションの重要な要因です。

3. データ品質とアノテーションの問題 **(Data Quality and Annotation Issues)**

訓練データの全体的な品質、特にアノテーション（人間によるラベル付け）の質も、ハルシネー

ションの発生に影響します。

- 低品質・ノイズの多いデータ: 訓練データが不完全であったり、ノイズが多かったり、あるいは意図的に汚染されたデータ（敵対的攻撃による破損など）を含んでいたりする場合、モデルはこれらの欠陥から誤ったパターンを学習し、ハルシネーションを生成しやすくなります [1]。これは、特に事実の正確性が重視される応用分野で問題となります。

これらのデータ起因の要因を総合すると、LLMが訓練データに含まれる知識の範囲や質、そして不確実性をどの程度理解し、扱えるかという点が、ハルシネーションの発生頻度や性質に深く関わっていることがわかります。特に、モデルが馴染みのない知識に直面した際に過度に自信を持って応答してしまう傾向 [10] は、知識の欠如と自信過剰という危険な組み合わせを示唆しており、モデルの信頼性評価が不十分である可能性を示しています。この現象は、モデルが特定の事実的根拠がない場合でも、学習した流暢な生成パターンに頼ってしまうこと、そしてRLHFのような訓練目的が、もっともらしいが不正確な出力を意図せず強化してしまうこと [1] に起因する可能性があります。

B. モデルアーキテクチャと学習プロセス起因の要因 (Model Architecture and Training Process Factors)

LLMの内部構造や学習方法自体も、ハルシネーションを引き起こす要因となり得ます。

1. デコーディング戦略 (Decoding Strategies)

テキスト生成時、次のトークンを選択するためのデコーディング戦略もハルシネーションの発生に関与します。例えば、常に最も確率の高いトークンを選択するgreedy searchや、低い温度（temperature）設定でのサンプリングは、生成されるテキストの多様性を低下させ、反復的で予測可能な、時には事実に反する内容を生成しやすくする可能性があります [1]。これらの戦略は、確率分布のピークに過度に依存するため、より創造的で文脈に合った、あるいは事実に基づいた代替案を見逃すことがあります。

2. 強化学習とフィードバック (Reinforcement Learning and Feedback)

人間からのフィードバックに基づく強化学習（RLHF）は、LLMの出力を人間の好みや指示に沿うように調整するために広く用いられています。しかし、このプロセスがハルシネーションを助長する可能性も指摘されています。

- **RLHFの過度な最適化:** RLHFプロセスにおいて、モデルが人間の評価者が好むような、流暢で一見もっともらしい応答を生成することに過度に最適化された結果、事実の正確性が犠牲になることがあります [1]。モデルは、事実よりも「人間が好む応答」を優先するようになり、これがハルシネーションの増加につながるというわけです。

3. ハードラベルと過信 (Hard Labels and Overconfidence)

教師あり学習におけるラベルの扱い方も、モデルの過信とハルシネーションに関連していま

す。

- ハードラベルの問題点: 従来の教師ありファインチューニングでは、各入力に対して単一の「正解」出力（ハードラベル）が与えられます。しかし、自然言語は本質的に多様な表現や解釈を許容するため、このような決定論的な教師付けは、モデルに過度の自信を植え付け、不確実性を無視させる傾向があります [2]。特に曖昧な文脈や複数の妥当な応答が存在しうる状況で、ハードラベルはモデルを誤った方向に導き、自信を持って不正確な出力を生成する（つまりハルシネーションを起こす）原因となり得ます [2]。

4. 自己回帰モデルにおける誤差蓄積 **(Error Accumulation in Autoregressive Models)**

LLMの多くは自己回帰モデルであり、トークンを一つずつ順番に生成します。この逐次的な生成プロセスは、誤差が蓄積しやすいという性質を持っています。

- 誤差の伝播と増幅: 生成プロセスのある段階で誤ったトークンが選択されると、その誤りが後続のトークン選択のコンテキストとなり、さらなる誤りを誘発する可能性があります [4]。このようにして初期の小さな誤りが徐々に蓄積・増幅し、最終的に文全体としてハルシネーションと見なされるような不正確な内容に至ることがあります。
- バイアスの蓄積: モデルの複数の層を情報が通過する過程で、各層で生じる微小なバイアスが蓄積し、最終的な出力がモデル内部の推論プロセスや真のデータ分布から乖離することがあります [4]。この結果、出力トークンの確率（信頼度）だけでは、その応答がハルシネーションであるかどうかを正確に判断できなくなることがあります。

5. 位置依存性と視覚情報の無視（マルチモーダルモデル）**(Positional Dependence and Ignoring Visual Input in Multimodal Models)**

画像と言語を統合的に扱う大規模視覚言語モデル（LVLM）においても、特有のハルシネーションパターンが見られます。

- 生成後半でのハルシネーション増加: LVLMが画像キャプションなどを生成する際、生成されるテキストの後半部分でハルシネーション（例：画像に存在しない物体や属性を記述する）が発生しやすい傾向が報告されています [16]。
- 視覚情報への依存低下: この現象の一因として、モデルがテキスト生成を進めるにつれて、入力された視覚情報への依存度を徐々に低下させ、代わりに学習済みの言語的な事前知識（言語モデルとしての傾向）により強く依存するようになるためではないかと考えられています [16]。Yaqi Sunら (arXiv:2502.16842) の研究が、この現象を詳細に分析しています。

これらのモデルアーキテクチャや学習プロセスに起因する要因は、ハルシネーションが単なるデータの問題ではなく、LLMというシステム自体の特性と深く結びついていることを示唆しています。特に、学習理論に基づくハルシネーションの不可避性の議論 [18] や、自己回帰モデルにおける誤差蓄積のメカニズム [4] は、ハルシネーションが現在のLLMパラダイムに内在する根深い問題であることを示唆しています。これは、ハルシネーション対策が、単にデータ点を修正

したり、モデルの一部分を調整したりするだけでは不十分であり、より根本的なアーキテクチャや学習方法の革新、あるいはハルシネーションを完全に排除するのではなく「管理」するという発想の転換が必要になる可能性を示しています。

C. 知識関連の競合 (Knowledge-Related Conflicts)

LLMが情報を処理し生成する際には、異なるソースからの知識が利用されます。これらの知識ソース間で矛盾や競合が生じると、ハルシネーションが発生することがあります。

1. パラメトリック知識 vs. 文脈/外部知識 (Parametric vs. Contextual/External Knowledge)

- **パラメトリック知識:** LLMが事前学習の過程でモデルのパラメータ内に獲得・符号化した知識を指します。
- **文脈知識/外部知識:** 推論時にプロンプトとして与えられる情報や、検索拡張生成（RAG）システムにおいて外部データベースから検索されてくる情報を指します。

これらの異なる知識ソース間で内容が矛盾する場合、LLMはどちらを優先すべきか混乱し、結果としてハルシネーションを生成する可能性があります。特にRAGシステムでは、この問題が顕著に現れます。RAGは、外部知識を提供することでLLMのハルシネーションを抑制することを目的としていますが、検索された外部知識がLLMの持つパラメトリック知識と衝突した場合、かえってハルシネーションを引き起こすことがあります [20]。

Xuら (2024) の研究 [20] やYi Suiら (arXiv:2506.06240) の研究 [21] は、この知識の競合問題に焦点を当てています。[20]では、ハルシネーションが、LLM内部の知識を処理するFFN（Feed-Forward Networks）がパラメトリック知識を過度に重視し、一方で検索された外部知識を取り込むためのアテンションヘッド（Copying Headsと呼ばれる）が外部知識を効果的に保持・統合できない場合に発生する、というメカニズムが示唆されています。

この「RAGパラドックス」とも言える現象、すなわちハルシネーションを解決するために導入された技術が新たなハルシネーションの原因となりうるという事実は、RAGシステムが単純な情報の付加だけでは不十分であり、より高度な知識統合メカニズムや競合解決戦略が必要であることを示しています。また、LLMにとって「知識」とは何か、という問題の複雑さも浮き彫りにします。単に情報に触れた（訓練データに含まれていた）というだけでは、その情報が確実に、そして正確に利用されるとは限りません。モデルがどの知識ソースを優先し、どのように情報を統合するかというプロセス自体が、ハルシネーションの発生に深く関わっています。

D. 本質的な限界と理論的視点 (Inherent Limitations and Theoretical Perspectives)

一部の研究では、ハルシネーションは現在のLLMの設計や学習方法における単なる欠陥ではなく、より根本的な、あるいは理論的な限界に起因する可能性が議論されています。

1. ハルシネーションの不可避性 **(Inevitability of Hallucination)**

- 学習理論からの示唆**:** Ziwei Xuら (arXiv:2401.11817) の研究 [18] は、学習理論の観点から、LLMが計算可能な全ての関数（つまり、あらゆる種類の問題解決パターン）を学習することは不可能であると論じています。このため、LLMを汎用的な問題解決器として使用しようとすると、原理的に学習できないパターンに遭遇した場合に、必然的にハルシネーション（つまり、不正確な出力を生成すること）を起こすと主張しています。
- **LLM**の構造的特性**:** 別の研究 [19] では、ハルシネーションはLLMの基本的な数学的・論理的構造に根差す本質的な特徴であり、アーキテクチャの改善、訓練データセットの強化、あるいは事実確認メカニズムの導入といった手段によっても、完全に排除することは不可能であると論じています。この視点によれば、訓練データの編集から、事実検索、ユーザーの意図分類、そして最終的なテキスト生成に至るまで、LLMが行う処理の各段階において、ハルシネーションを生成する確率がゼロではないとされています [19]。

これらの理論的考察は、ハルシネーションがLLMという技術パラダイムに深く組み込まれた課題であることを示唆しており、完全な撲滅ではなく、その発生を抑制し、影響を管理するというアプローチの重要性を強調しています。

以下の表2に、本節で議論したハルシネーションの主な原因をまとめます。

表**2:** ハルシネーションの主な原因の概要 **(Summary of Key Causes of Hallucinations)**

カテゴリ **(Category)**	具体的な原因 **(Specific Cause)**	簡単な説明 **(Brief Explanation)**	主要参考文献 **(Key References)**
データ起因 (Data-Driven)	データヴォイド、バイアス (Data Voids, Biases)	訓練データ中の知識の欠落や偏りが不正確な出力を生む。	[1]
	馴染みのない知識 (Unfamiliar Knowledge)	ファインチューニング時に未知の知識を与えると過信しハルシネーションを助長。	[14]
	低品質データ (Low-Quality Data)	ノイズの多い、または誤った情報を含むデータが誤学習を引き起こす。	[1]
モデルアーキテクチャ/学習 (Model	RLHFの過最適化 (RLHF	流暢さや好みを優先し、事実の正確性が犠牲に	[1]

Arch./Training)	Over-optimization)	なる。	
	ハードラベルによる過信 (Overconfidence from Hard Labels)	決定論的な教師が不確実性を無視させ過信を生む。	2
	自己回帰モデルの誤差蓄積 (Error Accumulation in Autoregressive)	生成過程で初期の誤りが後続に影響し増幅する。	4
知識の競合 (Knowledge Conflict)	パラメトリック知識 vs. 外部知識 (Parametric vs. External Conflict)	RAG等で内部知識と外部検索知識が矛盾するとハルシネーション発生。	20
本質的限界 (Inherent Limitations)	計算可能な全関数の非学習性 (Inability to Learn All Computable Functions)	学習理論上、LLMは全てのパターンを学習できず必然的にハルシネーション。	18
	LLMの構造的特性 (Structural Nature of LLMs)	LLMの基本構造自体がハルシネーションを不可避にする。	19

IV. ハルシネーションの対策と管理戦略 (Strategies for Mitigating and Managing Hallucinations)

ハルシネーションの複雑な原因に対応するため、研究コミュニティは多岐にわたる対策と管理戦略を開発・提案しています。これらの戦略は、ハルシネーションを検出しようとするもの、データ準備段階で対処しようとするもの、モデルの学習や構造自体を改善しようとするもの、外部知識の利用方法を工夫するもの、そしてモデル自身に誤りを修正させようとするものなど、様々です。

A. 検出技術 (Detection Techniques)

ハルシネーションを効果的に管理するための第一歩は、それがいつ発生しているかを正確に検出することです。

1. 不確実性推定 (Uncertainty Estimation)

モデルが自身の出力に対してどの程度の「自信」を持っているかを定量化し、その自信が低い（つまり不確実性が高い）場合にハルシネーションの可能性が高いと判断するアプローチです

[1]。

- 出力確率の分析: 生成される各トークンの確率分布のエントロピーを計算したり、複数の異なる出力を生成させて（例：Monte Carlo Dropout）、そのばらつきを評価したりすることで、モデルの不確実性を推定します [1]。
- 内部状態の利用: 単に出力レベルの信頼度だけでなく、モデルの内部状態（例えば、特定の隠れ層の活性化パターン）を分析し、そのパターンから出力の真偽を予測する分類器を訓練するアプローチも研究されています [1]。しかし、[4]で指摘されているように、出力層の信頼度だけでは不十分な場合があります。モデルの層を通じてバイアスが蓄積することで、最終出力の信頼度が内部の推論プロセスと乖離し、信頼できないシグナルとなることがあるためです [4]。

2. 事実検証 **(Fact Verification)**

生成されたコンテンツの内容を、信頼できる外部の知識ベース（例えば、Wikipediaや専門分野のデータベース）と照合し、事実との矛盾を検出する手法です [1]。検索拡張生成（RAG）の枠組みと組み合わせ、検索によって得られた参照情報とLLMの生成内容を比較し、整合性を確認することも一般的です [1]。

3. 自己一貫性チェック **(Self-Consistency Checks)**

同じ入力プロンプトに対して、モデルに複数の異なる応答を（例えば、サンプリング温度を変えるなどして）生成させ、それらの応答間の一貫性を分析する手法です [1]。もし複数の応答間で内容に大きなばらつきが見られたり、矛盾が生じたりする場合、モデルがそのトピックについて確固たる知識を持っていない可能性、すなわちハルシネーションを起こしやすい状態にあることが示唆されます。多数決による自己一貫性評価や、クエリを言い換えて応答の一貫性を見る対照的一貫性評価などが提案されています [1]。

4. 内部状態モニタリングと摂動ベースの検出 **(Internal State Monitoring and Perturbation-based Detection)**

近年の研究では、LLMの最終出力だけでなく、その内部状態（隠れ層の活性化ベクトルやアテンションマップなど）を監視・分析することで、ハルシネーションの兆候をより深く捉えようとする動きが活発化しています。

- **SSP (Sensitive Self-Perturbation):** [4]、[4]、[4]で提案されているSSPは、入力に対して微小な摂動（ノイズ）を加え、それがモデルの中間表現にどのような変化を引き起こすかを観察します。この変化の度合いを増幅し、真実に基づいた応答とハルシネーションによる応答とを区別しようと試みます。この手法の背景には、事実に基づいた知識はモデル内部で比較的安定した、構造化された表現としてエンコードされており、入力の微小な変化に対して敏感に反応する一方、ハルシネーションによる応答は、そのようなしっかりとした内部表現に裏打ちされていないため、摂動に対して比較的安定している（変化しにくい）という観察があります [4]。

- 文脈注入と内部状態ドリフト: [7]、[8]、[8]の研究では、対話の過程で逐次的に文脈情報を注入していくと、モデルの内部状態（表現）がどのように変化（ドリフト）し、それがハルシネーションの発生頻度とどのように関連するかが体系的に調査されています。

このような内部状態に着目するアプローチは、モデルの「思考プロセス」をより直接的に探る試みであり、ハルシネーションの根本的なメカニズム解明と、より洗練された検出・制御手法の開発につながる可能性があります。これは、単に出力確率を見るだけでは捉えきれない、モデルの振る舞いの深層にある情報を活用しようとするものであり、「説明可能なAI（Explainable AI）」の追求とも軌を一にしています。

B. データ中心の対策 **(Data-Centric Mitigation)**

訓練データやファインチューニング用データの質を改善したり、選択方法を工夫したりすることで、ハルシネーションを抑制しようとするアプローチです。

1. 命令チューニングにおけるデータ選択 **(Data Selection in Instruction Tuning)**

命令チューニング（Instruction Tuning）は、LLMがユーザーの指示に従う能力を高めるための重要なプロセスですが、使用するデータによってはハルシネーションを助長する可能性があります。そのため、適切なデータを選択する戦略が研究されています。

- **NOVA**フレームワーク: このフレームワークは、LLMが事前学習段階で既に獲得している知識とよく整合する（つまり、LLMにとって「馴染みのある」）高品質な命令チューニングデータを特定し、選択することを目指します [14]。これにより、モデルが未知の知識に直面して過信し、ハルシネーションを生成するリスクを低減します。NOVAは、具体的には以下の2つの主要なコンポーネントを使用します:
  - 内部一貫性プロービング **(Internal Consistency Probing - ICP):** 与えられた指示に対してLLMに複数の応答を自己生成させ、それらの応答間の一貫性を（例えば、内部状態表現の類似性などを用いて）評価します。一貫性が高ければ、LLMはその指示内容をよく理解している（馴染みがある）と判断されます [14]。
  - 意味的等価性同定 **(Semantic Equivalence Identification - SEI):** 命令データセット中の目標応答（人間が作成した模範解答など）と、LLMが自己生成した応答との間の意味的な類似性や等価性を評価します。これにより、目標応答がLLMの知識範囲内にあるかどうかを判断します [14]。
- **GRait**フレームワーク: このフレームワークは、LLMが自身の知識の範囲を超える質問に対して適切に「知らない」と応答（拒否応答）する能力を高めることで、ハルシネーションを削減することを目指します 。GRaitは、勾配情報（モデルパラメータが各サンプルから受ける影響の度合い）を利用して、命令チューニング用のサンプルを選択します。特に、「idk (I don't know)セット」（モデルが正しく答えられない、つまり拒否すべきと判断される質問群）の中から、拒否応答の学習に最も効果的なサンプル（拒否影響度が大きいサンプル）を効率的に選択し、過度な拒否（知っていることまで拒否してしまう）を避けつつ、ハルシ

ネーションを最小化しようとします 。

これらのデータ選択戦略は、LLMに「知らないこと」を認識させ、不確実な場合に無理に回答を生成するのではなく、適切に拒否する能力を植え付けることの重要性を浮き彫りにしています。これは、信頼できるAIシステムを構築する上で不可欠な「認識論的謙虚さ（epistemic humility）」をモデルに持たせる試みと言えます。

C. モデル中心の対策 (Model-Centric Mitigation)

モデルのアーキテクチャ自体や学習方法、ファインチューニングのプロセスを改良することで、ハルシネーションを根本的に抑制しようとするアプローチです。

1. 知識蒸留 (Knowledge Distillation)

知識蒸留は、大規模で高性能な「教師モデル」の知識を、より小規模な「生徒モデル」に転移させる手法です。ハルシネーション対策としては、教師モデルが生徒モデルに対して、単一の正解ラベル（ハードラベル）ではなく、より滑らかで確率的な情報を含む「ソフトラベル」を提供することで、生徒モデルの過信を抑制し、事実に基づいた応答生成（ファクチュアル・グラウンディング）を改善することが期待されます [2]。特に、命令データに対する教師ありファインチューニングの際に知識蒸留を適用することで、ハードラベルが引き起こす決定論的な教師付けの問題（不確実性の無視や過信の助長）を緩和し、よりロバストでハルシネーションを起こしにくいモデルを育成することを目指します [2]。

2. ファインチューニング戦略 (Fine-Tuning Strategies)

既存の事前学習済みLLMを特定のタスクやドメインに適応させるファインチューニングの段階で、ハルシネーションを抑制するための特別な工夫を凝らすアプローチも多数提案されています。

- **NoiseFiT (Noise-Augmented Fine-Tuning):** このフレームワークは、ファインチューニングプロセス中に、モデルの内部状態の信号対雑音比（SNR）に基づいて適応的にノイズを注入することで、モデルの頑健性（ロバストネス）を高め、結果としてハルシネーションを削減することを目指します [5]。NoiseFiTはさらに、標準的なクロスエントロピー損失に加え、ソフトターゲット（教師モデルの出力確率分布など）に対するソフトクロスエントロピー損失や、ノイズを加えた複数のフォワードパス間での出力の一貫性を促す正則化項などを組み合わせた「ハイブリッド損失関数」を提案しています。これにより、ノイズの多い訓練条件下でも安定かつ正確な出力を維持し、ハルシネーションを抑制する効果が期待されます [5]。

D. 検索拡張生成（RAG）アプローチ (Retrieval-Augmented Generation (RAG) Approaches)

検索拡張生成（RAG）は、LLMが応答を生成する際に、外部の知識ソースから関連情報をリア

ルタイムで検索し、その情報をプロンプトの一部としてLLMに提供することで、より事実に基づいた、文脈に即した応答を促す技術です。ハルシネーション対策の文脈では、LLMが自身の内部知識（パラメトリック知識）の限界を超えて、最新かつ正確な情報に基づいて応答できるようにすることを目的としています。

1. 基本的な**RAG**とその役割 **(Foundational RAG and its role)**

基本的なRAGシステムは、ユーザーからのクエリを受け取ると、まず外部の文書データベース（例：Wikipedia、社内文書、専門文献など）から関連性の高い情報を検索する「リトリーバー（Retriever）」と、検索された情報と元のクエリを組み合わせて最終的な応答を生成する「ジェネレーター（Generator）」（通常はLLM）から構成されます [25]。このアプローチにより、LLMが訓練データに含まれていない最新情報や、特定のドメインに特化した専門知識に基づいて応答を生成できるようになり、パラメトリック知識の限界（例えば、知識の陳腐化、事実の不整合、特定ドメインへの適応性の低さなど）に起因するハルシネーションを軽減することが期待されます [26]。

2. 高度な**RAG**技術 **(Advanced RAG Techniques)**

基本的なRAGはハルシネーション削減に有効な手段ですが、それ自体が新たな課題を生むこともあります。例えば、リトリーバーが不適切な情報やノイズの多い情報を検索してきたり、検索された情報とLLMの内部知識が矛盾したり、検索された情報をLLMがうまく応答に統合できなかったり（グラウンディングの忠実性の欠如）する場合があります [26]。これらの課題に対応するため、より高度で洗練されたRAG技術が次々と開発されています。この分野は非常に活発な研究領域であり、単純な外部情報の付加から、より複雑でインテリジェントな知識統合システムへと進化しています。

- 反復的**RAG (Iterative RAG):** 複雑な質問や多段階の推論が必要な場合、一度の検索だけでは十分な情報が得られないことがあります。反復的RAGは、LLMによる推論と外部からの情報検索を複数回繰り返すことで、段階的に必要な情報を収集し、より深い理解に基づいた応答を生成しようとします [27]。
    - **R3-RAG (Reinforcement Learning for Retrieval-Reasoning RAG):** 強化学習を用いて、LLMに段階的な推論と効果的な情報検索の戦略を学習させます。このフレームワークでは、最終的な回答の正しさ（結果報酬）だけでなく、検索された文書がユーザーの質問に対して適切であるか（プロセス報酬）も評価基準に加えることで、より質の高い検索と推論の連鎖を目指します [27]。
    - **KnowTrace:** 従来の反復的RAGが検索された情報を単純にコンテキストに積み重ねていくのに対し、KnowTraceは、LLMが自律的に望ましい知識の三つ組（サブジェクト-プレディケート-オブジェクトの形式）をトレースし、入力された質問に特化した知識グラフを動的に構築・編成します [28]。これにより、コンテキストの過負荷を軽減し、より高品質な多段階推論を支援します。
- 自己修正**RAG (Self-Corrective RAG / Corrective RAG):** LLM自身が、リトリーバー

によって検索された情報の品質や関連性を評価し、もし品質が低いと判断した場合には、異なる情報源から再検索を試みたり、検索戦略を修正したりするメカニズムを組み込んだRAGです [[30] (arXiv:2401.15884.pdf を参照), [31] (STAFフレームワーク)]。

- 知識グラフ活用**RAG (Knowledge Graph-enhanced RAG - GraphRAG):** 事前に構築された知識グラフ（KG）を外部知識ソースとして利用し、エンティティ間の関連性といった構造化された情報を検索してLLMの応答生成に活用します [9]。これにより、より正確で文脈に富んだ応答が期待されます。例えば、FactRAG [9] は、生のテキストからエンティティとそれらの間の関係を抽出し、簡潔な「ファクト」の形でLLMに提供することで、ノイズを減らし理解しやすい情報を提供します。
- **DSSP-RAG (Dual-Stream Knowledge-Augmented Framework for Shared-Private Semantic Synergy):** LLMのパラメトリック知識と検索された外部知識との間の競合を解決するために、これらの知識を「共有された意味」と「プライベートな意味（各知識ソースに固有の情報）」に分解し、それらを効果的に統合するための混合アテンションメカニズムを導入したフレームワークです [21]。さらに、認知的不確実性に基づく教師なしハルシネーション検出モジュールや、EQ（Energy Quotient）と呼ばれる指標を用いた外部知識のフィルタリング機能も備えています [21]。
- その他の高度な**RAG**戦略**:** [26]では、検索ノイズを軽減するためのRAAT（Retrieval-Augmented Adversarial Training）やCRAG（Corrective RAG）、ハルシネーション削減に特化したStructured RAG（検証済みのコーパスのみに検索を限定）やIM-RAG（反復的な検索結果の改良）といった手法も紹介されています。

これらの高度なRAG技術の開発は、「RAGの軍拡競争」とも言える状況を呈しており、RAGが単なる外部知識の参照ツールから、LLMと緊密に連携し、知識の選択・評価・統合・競合解決まで行う、より知的なシステムへと進化していることを示しています。

E. 自己修正・自己批判メカニズム **(Self-Correction and Self-Critique Mechanisms)**

LLM自身に、生成した応答を評価し、その中に含まれる可能性のある誤りやハルシネーションを特定し、修正する能力を持たせようとするアプローチです。これは、モデルに一種の「内省」能力を与える試みと言えます。

- メカニズム**:** 多くの場合、外部知識ソースとの照合（検索検証）や、モデルの内部状態（例えば、出力の確信度や一貫性）の分析を通じて行われます [7]。Panら ([7] の参考文献) の研究では、自己批判と自己修正のメカニズムがエラー率を大幅に削減することが示されています。また、SelfCheckGPT [8] のような手法は、複数の異なる応答を生成し、それらの間の一貫性をチェックすることで、自己診断的にハルシネーションを検出しようとします。
- 内部ダイナミクスの活用**:** 文脈情報の注入がモデルの内部状態の「ドリフト」を引き起こし、それがハルシネーションの発生と関連していることを示した研究 [7] は、このような自己修正メカニズムがどのような内部シグナルに基づいて動作しうるかについての重要な洞察を提供します。

ハルシネーション対策は、単一の万能薬が存在するわけではなく、ここで紹介したような多様な戦略（データ処理、モデル改良、検索拡張、検出、自己修正など）を組み合わせた多層的な防御アプローチが必要となるでしょう。それぞれの戦略はハルシネーション問題の異なる側面に対処するため、これらを相補的に活用することで、より堅牢で信頼性の高いLLMシステムの構築が期待されます。

以下の表3に、本節で議論したハルシネーションの主要な対策戦略をまとめます。

表3: ハルシネーション対策戦略の概要 (Overview of Hallucination Mitigation Strategies)

カテゴリ **(Category)**	具体的な技術/フレームワーク **(Specific Technique/Framework)**	簡単な説明 **(Brief Description of Mechanism)**	主要参考文献 **(Key References)**
検出技術 (Detection)	不確実性推定 (Uncertainty Estimation)	モデル出力の信頼度を定量化し、不確実性が高い場合にハルシネーションを疑う。	1
	SSP (Sensitive Self-Perturbation)	入力摂動による中間表現の変化を分析し、真実応答とハルシネーションを区別。	4
データ中心 (Data-Centric)	NOVAフレームワーク	LLMの既知知識と整合する高品質データを特定・選択し、ファインチューニング。	14
	GRaitフレームワーク	勾配ベースで拒否応答学習に適したサンプルを選択し、ハルシネーションと過度な拒否を抑制。	
モデル中心 (Model-Centric)	知識蒸留 (Knowledge Distillation)	教師モデルからソフトラベルで学習し、過信を抑制。	2

	NoiseFiT (Noise-Augmented Fine-Tuning)	SNRに基づき適応的ノイズ注入とハイブリッド損失で堅牢性を向上。	5
RAGアプローチ (RAG)	KnowTrace	知識トリプレットをトレースし質問特化KGを構築、コンテキスト過負荷を軽減。	28
	DSSP-RAG	混合アテンションでパラメトリック知識と外部知識の共有・プライベート意味を分離・統合。	21
	GraphRAG	知識グラフから構造化情報を検索しLLM応答を強化。	9
	Self-Corrective RAG	検索情報の品質をLLMが評価し、低品質なら再検索。	30
自己修正 (Self-Correction)	自己批判・自己修正 (Self-Critique/Correction)	LLMが自身の生成応答を評価し、誤りやハルシネーションを特定・修正。	7

V. ハルシネーションと対策の評価 (Evaluating Hallucination and Mitigation Efficacy)

ハルシネーションの発生状況や、提案されている様々な対策手法の有効性を客観的に評価することは、この分野の研究を進展させる上で不可欠です。そのため、多様な評価指標やベンチマークデータセットが開発・利用されています。

A. 主要な評価指標とベンチマーク (Key Metrics and Benchmarks)

1. 評価指標 (Evaluation Metrics)

ハルシネーションの評価には、生成されたテキストの様々な側面を捉えるための指標が用いられます。

- 事実整合性指標 **(Factual Consistency Metrics):** 生成されたテキストが、既知の事実や提供された入力ソース（参照文書など）とどの程度整合しているかを評価します [1]。具体的な指標としては、以下のようなものがあります。

    - **FactScore:** 要約文などが元のソース文書に対してどの程度忠実であるかを、意味的および事実的な重複度を計算して測定します [1]。
    - エンティティレベル事実確認 **(Entity-Level Fact Checking):** 生成テキスト中の固有名詞、数値、重要な事実的記述などを特定し、外部データベースと照合して検証します [1]。
    - **FEVER**スコア**:** モデルが生成した主張に対して、Wikipediaから証拠を検索し、その主張が「支持される(Supported)」「反論される(Refuted)」「情報不足(Not Enough Information)」のいずれであるかを分類することで、事実の正確性を評価します [1]。
    - 忠実性 **(Faithfulness):** 特にRAGシステムの評価において、生成された応答が検索された関連文書の内容を正確に反映しているか、つまり応答とソース文書間の一貫性を測定します [25]。
- 意味的コヒーレンス・流暢性指標 **(Semantic Coherence and Fluency Metrics):** 生成されたテキストが、文法的に正しいだけでなく、論理的に一貫しており、自然で読みやすいかどうかを評価します [1]。
    - **BERTScore:** 生成テキストと参照テキスト（模範解答など）との間の意味的な類似性を、文脈化された単語埋め込み表現を用いて測定します [1]。
    - **BLEURT:** テキスト生成の品質に関する人間の評価を予測するように学習された評価指標です [1]。
- 不確実性ベース指標 **(Uncertainty-Based Metrics):** モデルが生成した出力に対して、どの程度の信頼度（確信度）を持っているかを定量化します [1]。これは、リスクの高い応用分野で特に重要となります。
- ハルシネーション率 **(Hallucination Rate):** モデルが応答を拒否しなかったケースのうち、不正解であった（ハルシネーションと見なされた）回答の割合を指します [11]。この指標は、モデルがどの程度の頻度で誤った情報を自信を持って提示してしまうかを直接的に示します。
- 人間評価 **(Human Evaluation):** 上記のような自動評価指標は有用ですが、ハルシネーションの微妙なニュアンスや文脈依存性を完全に捉えることはしばしば困難です。そのため、依然としてドメイン専門家やクラウドソーシングによる人間の評価者が、生成されたテキストの正確性、関連性、流暢さ、有害性などを手動で評価する手法が「ゴールドスタンダード」とされています [1]。この事実は、現在の自動評価指標が人間の判断を完全に代替するには至っておらず、特に「もっともらしいが誤っている」というハルシネーションの巧妙な性質を捉える上で限界があることを示唆しています。自動評価指標は意味的類似性などを測定できても、それが必ずしも事実の正確性を保証するわけではないためです。

2. ベンチマークとデータセット **(Benchmarks and Datasets)**

ハルシネーションの評価や対策手法の比較を標準化された条件下で行うために、様々なベンチマークデータセットが開発されています。

- **TruthfulQA:** モデルが、しばしば誤解を招きやすい質問や、一般的に信じられているが

実は誤っている俗説などに対して、事実に基づいて正しい回答を生成する能力をテストするために設計されたベンチマークです [1]。

- **FEVER (Fact Extraction and VERification):** 主張の事実整合性を評価するための大規模なデータセットで、各主張に対してWikipediaから抽出された証拠とともに「支持」「反論」「情報不足」のラベルが付与されています [1]。
- **HALL-E (Hallucination Evaluation for Large Language Models):** オープンエンドなテキスト生成タスクにおけるハルシネーションを評価するために、人間によるアノテーションが付与されたデータセットです [1]。
- **HaluEval:** 質問応答、知識に基づいた対話、要約といった多様な自然言語処理（NLP）タスクをカバーし、人間によるハルシネーションの深刻度アノテーションを含む大規模なベンチマークです [1]。
- **MultiHal:** 知識グラフ（KG）に基づいてLLMのハルシネーションを多言語環境で評価するために提案されたデータセットです [29]。これは、構造化された事実知識を評価の基盤とすることで、より厳密な事実性の検証を目指しています。

これらの多様なベンチマークの存在は、ハルシネーションの評価が一律に行えるものではなく、対象とするタスクの種類（例：質問応答、要約、対話）、ハルシネーションのタイプ（例：事実的誤り、文脈不整合）、そして評価の側面（例：真実性、KGとの整合性、多言語性）に応じて、適切なベンチマークを選択する必要があることを示しています。単一のスコアやベンチマークでは、モデルのハルシネーション傾向を包括的に評価することは困難であり、多角的な評価アプローチが求められます。

VI. 結論と今後の展望 (Conclusion and Future Outlook)

A. 主要な知見の要約 (Summary of Key Findings)

本報告書では、arXivで公開されている最新の研究論文に基づき、生成AI、特に大規模言語モデル（LLM）におけるハルシネーションの発生原理とその対策について包括的に分析しました。主要な知見は以下の通りです。

1. **ハルシネーションの遍在性と深刻性:** ハルシネーションは、生成AIの信頼性と実用性を脅かす遍在的かつ深刻な課題です。その定義は多様であり、内在的/外在的、事実的/意味的といった分類に加え、特定の応用分野における影響を考慮した「腐食性ハルシネーション」といった概念も提案されています。
2. **原因の多様性と複雑性:** ハルシネーションの原因は単一ではなく、訓練データの限界やバイアス、モデルアーキテクチャや学習プロセスの特性（RLHFの過最適化、自己回帰モデルの誤差蓄積など）、内部知識と外部知識の競合、さらにはLLMの計算論的な本質的限界に至るまで、多岐にわたる要因が複雑に絡み合っています。
3. **対策アプローチの多角化:** ハルシネーションに対処するため、検出技術の向上（不確実性推定、内部状態モニタリングなど）、データ中心のアプローチ（高品質なデータ選択、拒否応答学習など）、モデル中心のアプローチ（知識蒸留、ノイズ注入ファインチューニング

など）、検索拡張生成（RAG）システムの高度化、そして自己修正・自己批判メカニズムの導入といった、多角的な研究開発が進められています。

4. **RAG**技術の急速な進化: 特にRAGは、単純な外部知識の検索・付加から、反復的検索、知識グラフの活用、さらにはLLMの内部知識との動的な競合解決メカニズム（例：DSSP-RAG）を備えた、より高度で知的なシステムへと急速に進化しています。
5. 評価の重要性と課題: ハルシネーションの評価には多様な指標とベンチマークが用いられていますが、自動評価の限界も認識されており、依然として人間による評価が重要視されています。タスクやハルシネーションのタイプに応じた適切な評価方法の選択が求められます。

B. 継続的な課題と今後の研究方向 (Ongoing Challenges and Future Research Directions)

ハルシネーション問題の解決に向けて多くの進展が見られる一方で、依然として多くの課題が残されており、今後の研究における重要な方向性を示唆しています。

- 標準化された定義と分類法の欠如: ハルシネーションに関する用語の定義や現象の分類について、研究コミュニティ内で完全に統一されたコンセンサスはまだ形成されていません[1]。より精密な議論と効果的な対策法の開発のためには、この点の標準化が一層求められます。
- スケーラブルで汎用的な緩和技術の開発: 現在提案されている多くの緩和技術は、特定の条件下やタスクにおいては有効性を示していますが、あらゆる状況で普遍的に機能し、かつ大規模モデルにも容易に適用可能な（スケーラブルな）解決策はまだ確立されていません[1]。
- 人間と**AI**のハイブリッド検証システムの構築: 特にクリティカルな応用分野においては、AIによる自動検出・修正と、人間の専門家による最終確認・判断を組み合わせた、信頼性の高いハイブリッドな検証ワークフローの設計が重要となるでしょう[1]。
- 「腐食性ハルシネーション」への効果的な対処: 特に科学研究などの分野で問題となる、推論プロセス全体を蝕むような「腐食性ハルシネーション」を効果的に中和するためには、モデルの訓練段階で理論的な制約を導入したり、推論時に戦略的なエラーフィルタリング機構を組み込んだりするなど、より踏み込んだ対策が必要です[3]。
- **LLM**の「創造性」とハルシネーションのバランス: ハルシネーションは一般的に否定的な現象として捉えられていますが、一部の研究では、それがLLMの「創造性」や新規なアイデア生成と関連している可能性も探求されています[32]。この観点は、ハルシネーションを一概に「バグ」としてのみ捉えるのではなく、文脈によっては「特徴」としての側面も持ちうるという、よりニュアンスのある理解を促します。今後の課題は、有害な事実誤認と、創造的な応用において有益となりうる（厳密には事実に即していないかもしれないが）新規な生成とを区別し、前者を選択的に抑制しつつ後者の可能性を活かすような、文脈依存的なハルシネーション管理戦略を開発することにあるかもしれません。
- ハルシネーション発生メカニズムの根本的理解の深化: ハルシネーションがなぜ、どのよ

うにして発生するのか、特にモデルの内部ダイナミクス（アテンションメカニズムの挙動、隠れ層における表現のドリフトなど）とハルシネーションの具体的な関連性についての理解をさらに深めることが、より効果的な対策法の開発につながります[7]。

- 予防的かつシステム的な解決策へのシフト: 将来の方向性としては、発生後の対処（事後的な検出・修正）だけでなく、モデルの訓練方法、アーキテクチャ設計、そしてAIシステム全体のワークフローの中に、ハルシネーションを予防するためのメカニズムを積極的に組み込んでいくことが重要です[1]。標準化された分類法やスケーラブルな緩和技術の追求は、この分野が場当たり的な解決策から、より体系的で持続可能なアプローチへと成熟しつつあることを示しています。これは、AIライフサイクル全体を通じてハルシネーション問題を考慮に入れるという、より包括的な視点への移行を意味します。
- **AI**における「真実」という永続的な課題: これまでの広範な研究にもかかわらず、LLMが現実世界の事実に整合し、誤解を招く情報を生成しないように保証するという根本的な問題は、依然として中心的な未解決課題です。一部で議論されているハルシネーションの「不可避性」[18]は、完全な事実的信頼性の達成が漸近的な目標であり続ける可能性を示唆しており、これは単にアルゴリズムを改良するだけでなく、機械に「真実」を確実に把握させることの哲学的および実践的な限界についての継続的な探求が必要であることを意味しています。

生成AIにおけるハルシネーションは、技術的な挑戦であると同時に、AIと社会との関わり方においても重要な問いを投げかけています。この問題に対する継続的な研究と学際的な協力が、より信頼でき、安全で、有益なAI技術の未来を築く上で不可欠です。

引用文献

1. A Survey on Hallucination in Large Language and Foundation ..., 6月 9, 2025にアクセス、https://www.preprints.org/manuscript/202504.1236/v1
2. Mitigating LLM Hallucination with Smoothed Knowledge Distillation - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2502.11306v1
3. [2504.08526] Hallucination, reliability, and the role of generative AI in science - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2504.08526
4. Shaking to Reveal: Perturbation-Based Detection of LLM ... - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/pdf/2506.02696
5. Noise Augmented Fine Tuning for Mitigating Hallucinations in Large Language Models, 6月 9, 2025にアクセス、https://arxiv.org/html/2504.03302v1
6. Noise Augmented Fine Tuning for Mitigating Hallucinations in Large Language Models, 6月 9, 2025にアクセス、https://arxiv.org/html/2504.03302v2
7. Shadows in the Attention: Contextual Perturbation and Representation Drift in the Dynamics of Hallucination in LLMs - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2505.16894v1
8. Shadows in the Attention: Contextual Perturbation and ..., 6月 9, 2025にアクセス、https://www.arxiv.org/pdf/2505.16894
9. GraphRAG: Leveraging Graph-Based Efficiency to ... - ACL Anthology, 6月 9, 2025

にアクセス、https://aclanthology.org/2025.genaik-1.6.pdf
10. Beyond Misinformation: A Conceptual Framework for Studying AI Hallucinations in (Science) Communication - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2504.13777v1
11. HalluLens: LLM Hallucination Benchmark - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2504.17550v1
12. HILL: A Hallucination Identifier for Large Language Models - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2403.06710v1
13. Understanding and Evaluating Hallucinations in 3D Visual Language Models - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2502.15888v1
14. arxiv.org, 6月 9, 2025にアクセス、https://arxiv.org/html/2502.07340v1
15. Fewer Hallucinations, More Verification: A Three-Stage LLM-Based Framework for ASR Error Correction - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2505.24347v1
16. Exploring Causes and Mitigation of Hallucinations in Large Vision Language Models - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2502.16842v1
17. [2502.16842] Exploring Causes and Mitigation of Hallucinations in Large Vision Language Models - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2502.16842
18. Hallucination is Inevitable: An Innate Limitation of Large ... - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2401.11817
19. LLMs Will Always Hallucinate, and We Need to Live With This - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2409.05746v1
20. ReDeEP: Detecting Hallucination in Retrieval-Augmented Generation via Mechanistic Interpretability - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2410.11414v2
21. Mitigating Hallucination of LLMs with Shared-Private Semantic Synergy in Dual-Stream - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/pdf/2506.06240
22. Mitigating Hallucination of LLMs with Shared-Private ... - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2506.06240
23. GRait: Gradient-Driven Refusal-Aware Instruction Tuning for Effective Hallucination Mitigation - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2502.05911v1
24. arXiv:2504.03302v1 [cs.CL] 4 Apr 2025, 6月 9, 2025にアクセス、https://arxiv.org/pdf/2504.03302
25. Retrieval Augmented Generation Evaluation in the Era of Large Language Models: A Comprehensive Survey - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2504.14891v1
26. Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2506.00054v1
27. R3-RAG: Learning Step-by-Step Reasoning and Retrieval for ... - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2505.23794
28. KnowTrace: Bootstrapping Iterative Retrieval-Augmented ... - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/html/2505.20245
29. [2505.14101] MultiHal: Multilingual Dataset for Knowledge-Graph Grounded

Evaluation of LLM Hallucinations - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2505.14101
30. langgraph/docs/docs/tutorials/index.md at main - GitHub, 6月 9, 2025にアクセス、https://github.com/langchain-ai/langgraph/blob/main/docs/docs/tutorials/index.md
31. STAF: Leveraging LLMs for Automated Attack Tree-Based Security Test Generation - Scholarship@Western, 6月 9, 2025にアクセス、https://ir.lib.uwo.ca/cgi/viewcontent.cgi?article=13589&context=etd
32. A Survey on Large Language Model Hallucination via a Creativity Perspective - arXiv, 6月 9, 2025にアクセス、https://arxiv.org/abs/2402.06647